

Bidang Riset : Kebijakan
Rumpun Ilmu : Statistika

LAPORAN AKHIR
PERCEPATAN LEKTOR KEPALA (RPLK)



PEMODELAN DATA DERET WAKTU
BERDASARKAN KALENDER HIJRIYAH DENGAN
PENDEKATAN *MACHINE LEARNING*

Tahun ke 1 dari 2 Tahun

TIM PENELITIAN

Dr. Gungum Darmawan M.Si	[NIDN. 0018057302]
Budhi Handoko, M.Si, Ph.D	[NIDN. 0005108004]
Defi Yusti faidah, M.Si	[NIDN. 0015108801]

UNIVERSITAS PADJADJARAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
DESEMBER, 2023

HALAMAN PENGESAHAN

RISET PERCEPATAN LEKTOR KEPALA (RPLK)

Judul Riset : Pemodelan Data Deret Waktu Berdasarkan Kalender Hijriyah dengan Pendekatan *Machine Learning*

Bidang Riset/Rumpun : Statistika

Pusat Riset/Pusat Studi/ Pusat Unggulan UNPAD : Pemodelan dan Komputasi

Ketua Periset

1. Nama Lengkap : Dr.Gumgum Darmawan, M.Si
NIDN/NIP : 0018057302/197305182000121001
Jabatan Fungsional : Lektor
Program Studi : Statistika
No HP : 085975273439
Alamat Surel(E-mail) : gumgum@unpad.ac.id

Anggota Periset (1)

Nama Lengkap : Budhi Handoko, M.Si, Ph.D
NIDN/NIP : 0005108004/19801005 200501 1 003
Program Studi : Statistika

Anggota Periset (2)

Nama Lengkap : Defi Yusti Faidah, M.Si
NIDN/NIP : 0015108801/19881015 201212 2 003
Program Studi : Statistika


Tahun Pelaksanaan : 1 Tahun dari 2 Tahun

Biaya Tahun Berjalan : Rp 48.200.000,-

Biaya Keseluruhan : Rp 48.200.000,-

Bandung, 30 November 2023

Ketua Pelaksana,


(Dr.Gumgum Darmawan, M.Si)
NIP. 197305182000121001

Menyetujui:

Kepala Pusat Studi Pemodelan dan Komputasi,


(Dr.Gumgum Darmawan, M.Si)
NIP.19730518200012 1 001

Dekan FMIPA UNPAD


(Prof. Dr. Irfan Rahayu, S.Si, M.Si)
NIP. 19690208 199412 1 001

IDENTITAS DAN URAIAN UMUM RPLK

1. Judul Riset :

Pemodelan Data Deret Waktu Berdasarkan Kalender Hijriyah dengan Pendekatan *Machine Learning*

2. Tim Periset:

No.	Nama	Jabatan	Bidang Keahlian	Fakultas	Alokasi Waktu (Jam/Minggu)
1	Dr. Gumgum Darmawan, S.Si M.Si	Ketua	<i>Forecasting</i>	MIPA	12 Jam/ Minggu
2	Budhi Handoko, M.Si, Ph.D	Anggota	Data Science	MIPA	8 Jam/ Minggu
3	Defi Yusti Faidah, M.Si	Anggota	Komputasi Statistika	MIPA	8 Jam/ Minggu
4	Dian Islamiaty	Mhs S2	Statistika	MIPA	6 Jam/ Minggu
5	Akbar Artha Putra	Mhs S1	Statistika	MIPA	6 Jam/ Minggu
6	Ferdiyanto Valentino Putra Mangkawa	Mhs S1	Statistika	MIPA	6 Jam/ Minggu
7	Syahrul Ghani Abdul Rasyad	Mhs S1	Statistika	MIPA	6 Jam/ Minggu

3. Objek Riset (jenis material yang diteliti dan segi riset):

- Curah Hujan, Data Covid
- Harga Bahan Pangan
- Kalender Hijriyah

4. Masa Pelaksanaan

- Tahun I
Mulai : bulan Maret Tahun 2023
Berakhir : bulan Desember Tahun 2023

5. Usulan Biaya

- Tahun I
Anggaran Kegiatan Riset : Rp. 36.000.000,00
Anggaran Proses Luaran Riset : Rp. 12.200.000,00
Total : Rp. 48.200.000,00⁺

6. Pusat Riset/Pusat Studi : Pemodelan dan Komputasi

7. Instansi yang Terlibat (jika ada, dan uraikan apa kontribusinya)

Institusi	Kontribusi
BMKG,Dinas Kesehatan	Penyedia data
Diskominfo Kab. Bandung	Penyedia tempat dan peserta sosialisasi hasil penelitian

8. Temuan yang Ditargetkan (penjelasan gejala atau kaidah, metode, teori, produk, atau rekayasa)

- Temuan yang diharapkan adalah konversi data deret waktu harian menjadi data bulanan kalender hijriyah
- Pemodelan data deret waktu berbasis kalender hijriyah.
- Algoritma pemodelan data deret waktu menggunakan kalender hijriyah.

9. Kontribusi mendasar pada suatu bidang ilmu.

- Para peneliti dalam melakukan pemodelan data deret waktu untuk peramalan (*Forecasting*) dengan pendekatan *Machine Learning* menggunakan kalender Masehi. Hal ini terjadi karena data sekunder yang tersedia di berbagai instansi hanya tersedia dalam kalender masehi. Padahal tidak semua fenomena baik sosial maupun alam mengikuti kalender masehi. Indonesia dengan populasi muslim terbesar di dunia sangat erat dengan kalender hijriyah aktivitasnya.

10. Rencana Luaran Wajib:

Journal Internasional

No.	Journal	Penerbit	Quartile	Terindeks	Rencana Terbit
1	The Scientific World Journal	Hindawi	Q2	SCOPUS	2024

12. Rencana Luaran Tambahan (sebutkan rencana luaran tambahan)

1. Seminar Internasional
International Conference Applied Statistics 2023 (ICAS III), (UNPAD, November 2023).
2. Buku Cara Konversi Data Deret Waktu Ke Kalender Hijriyah

13. Tingkat Kesiapterapan Teknologi: TKT 4

DAFTAR ISI

IDENTITAS DAN URAIAN UMUM RPLK	ii
DAFTAR ISI	iv
RINGKASAN	vi
BAB 1. PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	3
BAB 2. TINJAUAN PUSTAKA DAN KERANGKA PEMIKIRAN	4
2.1. Model Model <i>Machine Learning</i>	4
2.1. 1 <i>Long Short-Term Memory</i> (LSTM).....	4
2.1.2 <i>Gated Recurrent Unit</i> (GRU).....	7
2.1.3 <i>Stacked</i> dan <i>Bidirectional RNN</i>	9
2.2. Kerangka Berfikir	10
2.3. Hipotesis	11
BAB 3. TUJUAN DAN MANFAAT.....	12
3.1 Tujuan Riset	12
3.2 Kegunaan atau Manfaat Riset.....	12
BAB 4. METODE Riset	13
4.1 Rancangan Riset.....	13
4.2 Data, Teknik pengumpulan data dan Sumber Data	13
4.3 Pengambilan/pemilihan sampel.....	13
4.4 Validitas dan reliabilitas data	13
4.5 Pengolahan dan analisis data.....	13
4.6 Lokasi dan Waktu Riset	14
BAB 5. HASIL DAN LUARAN YANG DICAPAI.....	15

BAB 6. RENCANA TAHAPAN BERIKUTNYA	16
BAB 7.KESIMPULAN DAN SARAN.....	17
7.1 Kesimpulan.....	17
7.2 Saran.....	17
DAFTAR PUSTAKA.....	18
LAMPIRAN-LAMPIRAN	23

RINGKASAN

Para peneliti di bidang *time series* khususnya *forecasting* khususnya di Indonesia menggunakan data berdasarkan kalender masehi. Di bidang kesehatan para peneliti meramalkan penyebaran Covid-19, di bidang ekonomi para peneliti memodelkan dan meramalkan pengeluaran penduduk perbulan, meramalkan kenaikan harga pangan, di bidang transportasi para peneliti meramalkan jumlah penumpang dan lain lain. Jika kita amati secara seksama, fenomena yang terjadi seperti penyebaran Covid-19, pengeluaran perbulan, kenaikan harga pangan dan peningkatan jumlah penumpang erat hubungannya dengan kalender hijriyah. Hal ini terjadi karena Indonesia merupakan penduduk dengan populasi muslim yang besar. Seperti penduduk sering berkumpul pada bulan Muharam, bulan Ramadhan dan Idul Fitri. Begitu juga lonjakan penumpang biasa terjadi ketika mudik lebaran. Selain itu fenomena diatas, data alam seperti pasang surut air laut, curah hujan masih relevan menggunakan kalender hijriyah. Pemikiran ini muncul dari penelitian Kohyama dan Wallace (2016) bahwa iklim di bumi seperti variasi curah hujan, pasang surut air laut dipengaruhi oleh fase bulan. Seperti kita ketahui, bahwa fase bulan merupakan perputaran bulan mengelilingi bumi yang merupakan landasan pembuatan kalender komariah (kalender hijriyah).

Masalah yang perlu dilakukan pemodelan berdasarkan kalender hijriyah adalah:

1. Bagaimana cara membentuk data runtun waktu berdasarkan kalender hijriyah.
2. Memodelkan data deret waktu dan meramalkan berdasarkan kalender hijriyah
3. Konversi balik dari kalender Hijriyah menjadi data harian untuk keperluan peramalan harian.

Kalender Hijriyah yang merupakan kalendernya mayoritas penduduk Indonesia diolah dengan pendekatan *Machine Learning, tool* yang sudah diakui para peneliti belakangan ini memiliki akurasi yang baik. Penelitian ini mendukung program riset unggulan Universitas Padjadjaran (Unpad), khususnya program kebijakan, budaya dan informasi.

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Kalender atau penanggalan (juga disebut almanak) adalah sistem penamaan suatu periode waktu (seperti hari dan bulan). Nama-nama ini disebut tanggal kalender, tanggal ini dapat didasarkan pada pergerakan benda langit seperti matahari dan bulan. Kalender yang mengacu pada pergerakan Bumi mengelilingi matahari dikenal dengan nama kalender Masehi, dari bulan Januari sampai Desember, banyaknya hari dalam satu tahun 365. Kalender yang mengacu pada perputaran Bulan mengelilingi Bumi biasa disebut kalender Hijriyah, dari bulan Muharam sampai Dzulhijah, banyaknya hari dalam setahun adalah 255.

Pada banyak penelitian di Indonesia, khususnya dalam bidang peramalan data yang digunakan untuk pemodelan mengacu pada kalender Masehi. Misalnya, peramalan banyaknya penumpang kereta api, peramalan curah hujan, peramalan penjualan suatu produk dan lain lain. Dalam kasus kasus tertentu misalnya jumlah penumpang, sangat diperlukan menggunakan kalender Hijriyah, karena pergerakan penduduk di Indonesia dipengaruhi oleh faktor agama (Islam). Seperti kita ketahui bahwa Indonesia sebagai negara mayoritas beragama Islam, melakukan mudik setiap tahunnya.

Konversi kalender sudah dilakukan oleh beberapa peneliti, diantaranya Almodarresi dan White (2004), Halari, dkk. (2015) Rashed dan Moklof (2017), Choi, dkk. (2018) dan Rashed, dkk. (2019). Para peneliti ini mengkonversi kalender untuk wilayah-wilayah di Timur Tengah dan Asia. Almodarresi dan White (2004), membuat algoritma untuk mengkonversi kalender Masehi (Gregorian) ke kalender *Khayyami*, yaitu kalender yang resmi digunakan di Iran dan Afghanistan.

Halari, dkk. (2015) mengkaji tentang keanehan (anomali) yang terjadi dalam kalender Islam yang digunakan untuk perdagangan di Timur Tengah khususnya Pakistan. Rashed dan Moklof (2017), menyarankan penggunaan kalender Islam konvensional. Choi, dkk. (2018) mengkaji perbedaan kalender China lama (*chongxiu-damingli*) dan kalender China baru (*Shoushili*)

berdasarkan pergerakan Matahari dan Bulan dengan mengacu pada gerhana Bulan. Rashed, dkk. (2019) membuat rumusan aritmatika untuk mengidentifikasi tahun Kabisat dalam kalender Hijriyah. Darmawan, dkk. (2021a) melakukan analisis korelasi data covid-19 di Indonesia berdasarkan kalender Hijriyah, hasilnya penyebaran covid-19 di Indonesia berkorelasi dengan Kalendar Hijriyah dibanding kalender masehi. Kemudian, Darmawan, Rosadi dan Ruchjana (2021b) melakukan peramalan penyebaran covid-19 di berbagai negara berpenduduk muslim yang tinggi selama bulan Ramadan.


Penelitian yang berkaitan dengan penggunaan variasi kalender telah dilakukan oleh Suhartono dan Hamzah (2010), Suhartono, dkk. (2015), Apriliadara, dkk. (2016), Suhartono, dkk. (2017), Suhartono, dkk. (2018), Hikmawati, dkk. (2021), dan Permata, dkk. (2022). Penelitian ini mengkaji pengaruh variasi kalender dengan pendekatan kode atau *Dummy Variable*. Pada proposal ini, konversi dilakukan secara Shifting dari data runtun waktu berdasarkan data harian. Kelebihan metode Shifting dapat digunakan untuk berbagai metode runtun waktu sedangkan metode coding biasanya menggunakan regresi.

Dalam proposal ini, penulis akan membuat suatu algoritma konversi data harian data bulanan yang mengikuti kalender Hijriyah. Nama bulan dan jumlah hari merujuk pada website *islamicfinder*. Konversi kalender ini di latar belakang karena beberapa alasan, diantaranya;

- 1). Pergerakan ekonomi di berbagai negara dengan populasi muslim yang besar seperti negara-negara Timur Tengah dan Asia mengikuti kalender Hijriyah.
- 2). Fenomena alam di bumi seperti pasang surut air laut dan cuaca seperti hujan dipengaruhi oleh pergerakan bulan, (Kohyama dan Wallace, 2016).
- 3). Belum adanya suatu penelitian (khususnya bidang peramalan) yang menyatakan bahwa kalender Masehi lebih baik dibandingkan dengan kalender Hijriyah.

Adapun setelah membentuk data deret waktu Hijriyah selanjutan akan dilakukan pemodelan dengan *Machine Learning*. Model model *Machine*

Learning yang digunakan adalah Model LSTM (Long Short Term Memory) dan GRU (Gated Recurrent Unit) model model kelas Machine Learning sudah terbukti keakuratannya.



Gambar 1.1. Diagram fishbone penelitian

1.2 Rumusan Masalah

Masalah yang belum tersolusikan dari beberapa penelitian telah dilakukan untuk menganalisis data deret waktu berdasarkan kalender hijriyah adalah:

1. Membentuk data deret waktu berdasarkan kalender hijriyah.
2. Memodelkan data deret waktu berdasarkan kalender hijriyah.
3. Konversi balik dari kalender hijriyah ke data harian.


BAB 2. TINJAUAN PUSTAKA DAN KERANGKA PEMIKIRAN

2.1. Model Model Machine Learning

Time series atau deret waktu merupakan kumpulan observasi atau pengamatan yang dibuat secara beruntun (*sequentially*) atau berurut sepanjang waktu. Biasanya observasi dalam deret waktu tidaklah bebas atau berkorelasi. Dengan demikian, urutan waktu dari observasi menjadi penting. Hal ini tentu berakibat pada prosedur-prosedur dan teknik-teknik statistika yang berdasarkan pada asumsi bebas (*independent*) menjadi tidak berlaku lagi, sehingga diperlukan metode-metode dan pendekatan-pendekatan yang berbeda.

2.1.1 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari arsitektur RNN yang sama-sama memiliki jaringan berulang. LSTM diusulkan pada tahun 1997 oleh Sepp Hochreiter dan Jürgen Schmidhuber (Hochreiter & Schmidhuber, 1997). LSTM adalah arsitektur RNN yang dirancang khusus untuk mengatasi masalah *vanishing gradient* (Graves, et al., 2009). Arsitektur LSTM memperkenalkan *cell state*, tidak hanya *hidden state* seperti pada RNN. *Cell state* bekerja seperti *conveyor belt* yang membawa informasi dari masa lampau. *Hidden state* dimaksudkan untuk membawa informasi dari peristiwa sebelumnya dan menimpa setiap langkah secara tak terkontrol, sedangkan *cell state* dimaksudkan untuk menyimpan informasi penting jangka panjang (*long-term*) dan memberi model memori yang lebih lama tentang informasi masa lalu. Pada RNN perulangan jaringan hanya menggunakan satu lapisan sederhana, yaitu lapisan tanh. Hal inilah yang menjadi pembeda LSTM dengan RNN. Unit memori LSTM terdiri dari *forget gate* (gerbang lupa), *input gate* (gerbang masukan), dan *output gate* (gerbang keluaran), yang digunakan untuk mengontrol penyimpanan atau pembuangan informasi (Zhang & Xu, 2021). Gerbang-gerbang ini dapat mempelajari informasi mana yang penting untuk disimpan atau dibuang sehingga hanya informasi yang relevan yang digunakan untuk membuat prediksi.



Gambar 2. 1 Struktur gate (gerbang) *Long Short-Term Memory* (LSTM)

(Sumber: Phi, 2018)

Forget gate mengontrol berapa banyak status sel atau informasi yang perlu dihapus. *Input gate* mengontrol berapa banyak informasi yang perlu disimpan (ditambahkan) ke *cell state* yang baru. *Output gate* yang mengontrol berapa banyak informasi yang akan menjadi *hidden state* dikirim ke sel berikutnya (Toharudin, et al., 2021).

Semenjak LSTM diperkenalkan pada tahun 1997 sudah banyak peneliti-peneliti yang menggunakan metode ini untuk berbagai kasus, seperti analisis deret waktu dan analisis sentimen. Akan tetapi pada penerapannya LSTM memiliki perhitungan yang cukup kompleks dan komputasi yang tinggi. Oleh karena itu, pada penelitian ini peneliti mencari metode yang memiliki tingkat komputasi yang lebih sederhana, namun memiliki kinerja yang sebanding.

Langkah pertama dalam LSTM adalah memutuskan informasi mana yang akan dibuang dari *cell state*. Keputusan ini dibuat berdasarkan *forget gate* (f_t) dengan persamaan berikut:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1)$$

Langkah selanjutnya adalah menentukan informasi baru mana yang akan dimasukan (ditambahkan) kedalam *cell state*. Langkah ini memiliki dua proses: Pertama, lapisan *input gate* (i_t) menentukan nilai mana yang akan diperbaharui (*update*). Kedua, lapisan tanh membentuk sebuah vektor baru dari *candidate values* ($\tilde{c}$) yang merupakan kandidat informasi yang akan ditambahkan kedalam *cell state*. Kedua proses ini dideskripsikan dengan persamaan dibawah ini:

$$i_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_i) \quad (2.2)$$

$$\tilde{c} = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.3)$$

Kemudian, *cell state* lama (C_{t-1}) di-*update* menjadi *cell state* baru (C_t) yang ditulis dengan persamaan berikut:

$$C_t = f_t \otimes C_{t-1} \oplus i_t \otimes \tilde{c} \quad (2.4)$$

Langkah terakhir, putuskan informasi mana yang akan diproduksi sebagai output. Output ini diproduksi berdasarkan *cell state*, namun akan menjadi versi yang telah difilter. Pada langkah ini, *output gate* (o_t) memutuskan bagian mana dari *cell state* yang akan diproduksi sebagai output. Kemudian, *cell state* melewati lapisan tanh (untuk me-regulerisasi nilai menjadi antara -1 dan 1) dan mengalikannya dengan *output gate* sebagai berikut:


$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.5)$$

$$h_t = o_t \otimes \tanh(C_t) \quad (2.6)$$

Dari persamaan sebelumnya, W adalah parameter bobot, b adalah parameter bias, dengan subskripnya adalah gerbang (*gate*) yang sesuai. σ mewakili fungsi sigmoid, dan tanh adalah fungsi tangen hiperbolik (Zhang & Xu, 2021).

2.1.2 Gated Recurrent Unit (GRU)

Gated Recurrent Unit (GRU) merupakan pengembangan dari arsitektur RNN yang memiliki ide yang sama dengan unit LSTM namun dengan struktur yang lebih sederhana dan parameter yang lebih sedikit (Gao, et al., 2020). GRU adalah pengembangan yang cukup baru yang diusulkan oleh K. Cho pada tahun 2014 (Cho, Van Merriënboer, Bahdanau, & Bengio, 2014). Sama seperti *Long Short-Term Memory*, *Gated Recurrent Unit* juga dapat mengurangi masalah *vanishing gradient* dari *Recurrent Neural Network* (Ghods & Cook, 2019). Unit internal GRU mirip dengan unit internal LSTM, namun GRU menggabungkan *input gate* dan *forget gate* di LSTM menjadi satu *update gate* (Mateus, Mendes, Farinha, Assis, & Cardoso, 2021).



Gambar 2. 2 Struktur gate (gerbang) *Gated Recurrent Unit* (GRU)

(Sumber: Phi, 2018)

Gated Recurrent Unit (GRU) menghilangkan *cell state* pada LSTM dan hanya menggunakan *hidden state* untuk mentransfer informasi. GRU juga hanya memiliki dua *gate* yang disebut dengan *reset gate* dan *update gate*. *Update gate* sama seperti *forget gate* dan *input gate* pada LSTM, yang akan memilih informasi mana yang harus dibuang atau ditambahkan dengan memori sebelumnya di dalam *hidden state*. Sedangkan *reset gate* digunakan untuk

menentukan seberapa banyak data atau informasi yang perlu dihapus (dilupakan) (Giarsyani, 2020).

GRU tergolong kedalam metode yang cukup baru, namun GRU sudah terbukti menunjukkan kinerja yang lebih baik pada kumpulan data tertentu (Gruber & Jockisch, 2020). *Gated Recurrent Unit* atau GRU merupakan alternatif yang lebih sederhana dibandingkan *Long Short-Term Memory* (LSTM) dan juga cukup populer (DiPietro & Hager, 2020).

Sama seperti Vanilla LSTM, Vanilla GRU merupakan arsitektur GRU yang hanya memiliki satu unit *hidden layer* GRU dan sebuah *output layer* dalam melakukan prediksi. Seperti yang dijelaskan pada bab sebelumnya, *update gate* (z_t) dan *reset gate* (r_t) pada lapisan GRU digunakan untuk mengontrol arah aliran data pada waktu ke- t (Pan, et al., 2018) dengan perhitungannya sebagai berikut:

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (2.7)$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (2.8)$$


Dimana x_t adalah input pada waktu ke- t , W_z adalah bobot dari *update gate*, W_r adalah bobot dari *reset gate*, dan h_{t-1} adalah output dari *hidden layer* (*hidden state*) sebelumnya.

Ketika menghitung $\tilde{h}_t$, yang merupakan *candidate hidden state* pada waktu ke- t , informasi waktu historis yang disebut juga *hidden state* (h_{t-1}) dipertahankan dan dikontrol dengan menyesuaikan nilai output dari *reset gate* (r_t), yang ditunjukkan pada perhitungan berikut:

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \otimes h_{t-1}, x_t] + b_h) \quad (2.9)$$

Langkah terakhir, *update gate* (z_t) untuk mengontrol berapa banyak informasi yang dilupakan dari *hidden state* sebelumnya dan berapa banyak informasi dalam *candidate hidden state* yang dipertahankan, hasil akhir yang dihitung dari *hidden state* yang baru adalah seperti yang ditunjukkan pada persamaan:

$$h_t = (1 - z_t) \otimes h_{t-1} + z_t \otimes \tilde{h}_t \quad (2.10)$$



Gambar 2. 3 **Arsitektur Gated Recurrent Unit (GRU)**

(Sumber: Abdulwahab, Jabreel, & Moreno, 2017)

Jika nilai *reset gate* mendekati 0, maka output *hidden layer* saat ini tidak akan dipertahankan, dan unit GRU akan membuang beberapa informasi historis yang tidak terkait dengan masa depan. *Update gate* menentukan berapa banyak informasi *hidden state* pada waktu ke-t-1 perlu disimpan dalam output *hidden layer* pada waktu ke-t. Jika elemen mendekati 1, informasi yang sesuai dari *hidden state* sebelumnya akan disalin ke *hidden state* waktu ke-t. Pada waktu ini, unit *update gate* dengan ketergantungan jarak jauh (*long-distance dependence*) aktif, sehingga informasi jarak jauh dapat dipelajari. Jika elemen mendekati 0, itu setara dengan RNN standar, dan informasi jarak pendek dapat diproses. Pada waktu ini, unit *update gate* dengan ketergantungan jarak pendek (*short-distance dependency*) aktif. Di bawah mekanisme ini, informasi historis dapat secara fleksibel membantu memprediksi informasi masa depan (Pan, et al., 2018).

2.1.3 Stacked dan Bidirectional RNN


Lapisan RNN dapat ditumpuk (*stacked*) menjadi metode yang berbeda. RNN satu arah yang ditumpuk memproses data dengan mengikuti aliran data yang sama (Althelaya, El-Alfy, & Mohammed, 2018). Metode ini terdiri dari banyak lapisan RNN bertingkat, setiap lapisan menggunakan aliran urutan data yang sama untuk melatih jaringan. Demikian pula dengan LSTM dan GRU. Dua

lapisan LSTM dapat di-*stacking* untuk membentuk arsitektur *Stacked* LSTM (SLSTM) dan dua lapisan GRU dapat di-*stacking* untuk membentuk arsitektur *Stacked* GRU (SGRU).

Di sisi lain, RNN dua arah (*bidirectional*) adalah cara lain untuk menumpuk lapisan RNN. Metode ini menggunakan data input dari masa lalu dan masa depan untuk melatih jaringan (Schuster & Paliwal, 1997). Jaringan terdiri dari dua lapisan yang terhubung, setiap lapisan melakukan operasi pada urutan input menggunakan arah aliran yang berbeda. Arsitektur *bidirectional* menggunakan satu lapisan untuk melakukan operasi mengikuti arah aliran yang sama dari urutan data. Lapisan lain secara terbalik menerapkan operasinya pada urutan data. Metode penggabungan yang berbeda digunakan untuk menggabungkan hasil akhir yang dihasilkan oleh lapisan jaringan. Sejalan dengan itu, dua lapisan LSTM dapat ditumpuk menggunakan dua arah aliran yang berbeda untuk memproses urutan input untuk membentuk arsitektur *bidirectional* LSTM (BiLSTM). Demikian pula, dua lapisan GRU dapat ditumpuk untuk membentuk arsitektur *bidirectional* GRU (BiGRU).

2.2. Kerangka Berfikir

Kerangka berpikir dalam penelitian ini dapat digambarkan pada Gambar 2.3 Konversi data kalender di bagi menjadi 3 segmen waktu.



Gambar 2.4 Kerangka Berfikir

Keterangan gambar

A : Awal (Masehi)	A1 : Awal (Hijriyah)
Z : Akhir (Masehi)	Z1 : Akhir (Hijriyah)
FY _A : Awal Tahun Masehi	FY _{A1} : Awal Tahun Hijriyah
LY _Z : Akhir Tahun Masehi	LY _{Z1} : Akhir Tahun Hijriyah
MC _A : Tengah kalender Awal Masehi	MC _{A1} : Tengah Kalender Awal Hijriyah
MC _Z : Tengah kalender Akhir Masehi	MC _{Z1} : Tengah kalender Akhir Hijriyah
Start : Awal tanggal	End : Akhir Tanggal

Gambar 2.4 mengilustrasikan konversi data dari data harian yang mengikuti kalender Masehi (*Gregorian Calendar*) menjadi data yang mengikuti kalender bulanan Hijriyah. Pada bagian atas garis horizontal, data di ukur dengan kalender Masehi dan bagian bawah garis horizontal diukur melalui kalender Hijriyah.

Gambar 2.4 dibagi menjadi 3 segmen waktu, yaitu *first year*, *middle calendar* dan *last year*. Segmen *first year* adalah bagian awal dari data yang di konversi, bagian ini merupakan satu tahun yang terpotong di awal. Segmen *middle calendar* merupakan bagian tengah yang utuh dari 1 Muharam sampai 29 Dzulhijah. Sedangkan *last year* adalah bagian akhir tahun yang terpotong di akhir kalender.

2.3. Hipotesis

Hipotesis dalam penelitian ini adalah Apakah pemodelan berdasarkan kalender hijriyah lebih baik (MAPE) dibandingkan dengan pemodelan berdasarkan kalender masehi.

BAB 3. TUJUAN DAN MANFAAT

3.1 Tujuan Riset

Tujuan penelitian yang akan dilakukan disusun dalam tujuan utama dan khusus berikut:

Tujuan Utama:

Memodelkan dan meramalkan data deret waktu berdasarkan kalender hijriyah.

Tujuan Khusus :

- a. Konversi data harian kekalender hijriyah
- b. Membuat algoritma *automatic conversion calendar*.

3.2 Kegunaan atau Manfaat Riset

Aspek Teoritis

- a. Didapatkannya algoritma *calender conversion* .
- b. Algoritma yang dihasilkan akan menjadi dasar penelitian lanjutan yang mengkaji tentang *automatic conversion calendar*.

Aspek Praktis

- a. Paket perhitungan yang dibangun berdasarkan perangkat lunak sumber terbuka akan banyak membantu bidang *time series*.
- b. Aplikasi terhadap data nyata akan membantu praktisi yang menggunakan data nyata tersebut untuk mengambil keputusan.

BAB 4. METODE RISET

4.1 Rancangan Riset

Penelitian ini menggunakan rancangan riset kuantitatif dengan tujuan mendapatkan suatu algoritma yang lebih akurat untuk menganalisis data deret waktu. Metoda dan teknik perhitungan yang didapatkan diaplikasikan terhadap data *Islamic finder*, sehingga didapatkan data deret waktu yang mengikuti kalender hijriyah.

4.2 Data, Teknik pengumpulan data dan Sumber Data

Data yang digunakan dalam penelitian ini adalah data skunder yang dikumpulkan dari berbagai sumber. Kumpulkan data time series yang akan diprediksi. Lakukan preprocessing data untuk mempersiapkan data agar siap untuk dilatih. Split data menjadi data training dan data testing. Unit analisis dalam penelitian ini meliputi data seluruh Indonesia untuk data, Kota-kota di Indonesia untuk Curah Hujan.

Pada langkah ini, data time series yang akan diprediksi dikumpulkan. Data time series dapat berupa data penjualan, harga saham, cuaca, dll. Data kemudian dipreprocess untuk mempersiapkan data agar siap untuk dilatih. Preprocessing data dapat meliputi langkah-langkah berikut:

- Mengisi nilai hilang (missing value).
- Mengubah format data.
- Mengaplikasikan normalisasi.

Setelah preprocessing, data kemudian displit menjadi data training dan data testing. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk mengevaluasi model.

4.3 Pelatihan Model

Buat model GRU atau LSTM dan Latih model pada data training. Pada langkah ini, model GRU atau LSTM dibuat dan dilatih pada data training. Model GRU dan LSTM adalah jenis jaringan saraf tiruan recurrent yang dapat digunakan untuk memprediksi data time series. Kedua model ini memiliki kemampuan untuk menangkap pola jangka pendek dan jangka panjang dalam data time series.

Pada langkah pelatihan, model akan mempelajari pola dalam data training. Pola ini kemudian digunakan untuk memprediksi data baru.

4.4 Pengolahan dan analisis data

Pengolahan data akan menggunakan *Singular Spectrum Analysis (SSA)* dan *Machine learning* seperti *LSTM (long short term memory)* dan *GRU (Gated Recurrent Unit)*. Dimana variabel kuantitatif yang dianalisis bersifat stokastik. Beberapa hal yang perlu diperhatikan dalam pengolahan data adalah pembangunan algoritma untuk melakukan *Hijriya calendar automatic conversion*:

4.5 Forecasting

Gunakan model yang telah dilatih untuk memprediksi data baru. Pada langkah ini, model yang telah dilatih digunakan untuk memprediksi data baru. Prediksi dapat dilakukan dengan menggunakan data testing atau data baru yang tidak termasuk dalam data training.

4.6 Evaluasi Hasil

Lakukan evaluasi model pada data testing. Pertimbangkan hasil evaluasi untuk menentukan model terbaik. Pada langkah ini, model dievaluasi pada data testing. Evaluasi model dilakukan untuk menentukan seberapa baik model dapat memprediksi data baru. Metode evaluasi yang umum digunakan untuk peramalan time series adalah root mean square error (RMSE), mean absolute error (MAE), dan mean absolute percentage error (MAPE).

4.7 Lokasi dan Waktu Riset

Lokasi penelitian pada Laboratorium departemen statistika dengan periode waktu penelitian selama satu tahun. Adapun tempat diskusi penulis biasa lakukan di kampus, Alfa-X dan Technolife.

BAB 5. HASIL DAN LUARAN YANG DICAPAI

Hasil dan luaran yang telah dicapai dari riset ini adalah sebagai berikut:

1) HaKI

HaKI yang diusulkan adalah Kode R untuk melakukan konversi data harian pada kalender masehi menjadi data bulanan pada kalender hijriyah.

Konversi ini digunakan untuk melakukan analisis deret waktu untuk data bulanan yang memenuhi fenomena musiman yang lebih sesuai untuk kalender hijriyah. Konversi dilakukan pada data harian curah hujan dari 1 Januari 2000 sampai dengan 31 Desember 2022.

2) Satu buah paper yang disubmit ke ***The Scientific World Journal*** (Q2) Hindawi, Egypt. Paper ini sudah mengalami dua kali revisi dari reviewer.

3) Satu buah paper yang disubmit ke *International Conference on Applied Statistics III (ICAS III)* yang akan diselenggarakan pada 1 – 2 November 2023. Paper tersebut akan diusulkan untuk disubmit ke Jurnal Data MDPI (Q2). Judul paper tersebut adalah *Comparison of LSTM and GRU Methods In Forecasting Rainfall in Bogor Regency*.

BAB 6. RENCANA TAHAPAN BERIKUTNYA

Rencana tim peneliti selanjutnya adalah menyelesaikan paper paper sebagai syarat dari Hibah ini. Selain itu kami akan menyelesaikan buku yang merupakan luaran tambahan.

Penelitian yang telah dilakukan menggunakan data yang harian yang digabungkan menjadi data bulanan. Penelitian selanjutnya dapat terus dengan menggunakan data harian secara utuh dari data curah hujan untuk berbagai model, GRU dan LSTM.

Topik yang sedang dikerjakan saat ini dijelaskan sebagai berikut:

Topik:

Perbandingan Metode Machine Learning untuk berbagai Metode seperti LSTM, Bi-LSTM, Stacked-LSTM dan GRU, BiGRU, Stacked-GRU Dalam Meramalkan Curah Hujan.

Tujuan:

Kabupaten Bogor memerlukan peramalan curah hujan sebagai salah satu pertimbangan dalam melakukan mitigasi untuk bencana banjir dan tanah longsor, salah satu hal yang bisa menjadi bahan pertimbangan adalah informasi mengenai prediksi curah hujan. Tujuan dari penelitian ini adalah untuk membandingkan berbagai metode LSTM dan GRU dalam melakukan peramalan curah hujan Kabupaten Bogor dalam dua kalender yang berbeda yaitu Kalender Masehi dan kalender Hijriyah.

Metode Penelitian:


- Berikut adalah langkah-langkah perhitungan dari LSTM :

1. Menghitung nilai pada forget gate .
2. Kalikan hasil dari *forget* dengan nilai cell state dari *timestep* sebelumnya.
3. Hitung nilai *input gate*
4. Hitung nilai dari *candidate value*
5. Kalikan hasil dari langkah 3 dan 4 lalu tambahkan dengan hasil dari langkah 2.
6. Hitung nilai dari *output gate*
7. Hitung nilai dari *hidden state* saat ini.

Berikut adalah langkah-langkah perhitungan dari GRU :

1. Hitung nilai *update gate*
2. Hitung nilai *rreset gate*
3. Hitung nilai dari *candidate hidden state*
4. Hitung nilai dari *hidden state*

Hasil deskriptifnya sebagai berikut;



BAB 7. KESIMPULAN DAN SARAN

7.1 Kesimpulan

Dengan menggunakan kalender bulan hasil peramalan menjadi akurat. Hal ini terjadi untuk berbagai model baik GRU, LSTM maupun Bi-LSTM. Kalender bulan ini bisa sebagai metode untuk meningkatkan akurasi dalam meramalkan tingkat curah hujan.

Dalam makalah ini, kami menggunakan metode deret waktu pembelajaran mesin dengan model BiLSTM dan pendekatan pencarian Grid. Keakuratan hasil peramalan data curah hujan berdasarkan kalender lunar dievaluasi menggunakan mean absolute percentage error (MAPE). Kami juga membandingkan MAPE model data curah hujan berbasis kalender Gregorian dan model data curah hujan berbasis kalender lunar.

MAPE terendah untuk model berbasis kalender Gregorian adalah 35,12%, sedangkan MAPE terendah untuk model berbasis kalender Lunar adalah 14,82%, dengan panjang perkiraan 3 bulan. MAPE yang lebih kecil untuk model berbasis kalender Lunar menunjukkan kemampuan peramalan yang unggul dibandingkan dengan model berbasis kalender Gregorian. Menurut kriteria MAPE, model peramalan berdasarkan kalender Lunar dapat dianggap sangat akurat. Kombinasi optimal parameter untuk data curah hujan berdasarkan kalender Lunar, sebagaimana ditentukan melalui algoritma Pencarian Grid, terdiri dari 20 neuron, 200 zaman, ukuran batch 4, dan nilai putus sekolah 0,1.

7.2 Saran

Perlu kolaborasi dengan dengan peneliti lain misal dengan para peneliti dari BMKG agar memberikan hasil yang lebih akurat. Dalam kalender hijriyah perlu berkolaborasi dengan ahli astronomi bagaimana pergerakan bulan, fase dan gravitasi bulan mempengaruhi cuaca di Bumi. Selain itu perlu dikaji factor-faktor eksternal yang mempengaruhi cuaca, khususnya curah hujan yang terjadi di bumi.

Konversi data curah hujan berbasis Gregorian ke kalender Lunar memberikan keuntungan dalam analisis deret waktu. Konversi data harian ke data bulanan berdasarkan kalender lunar meningkatkan panjang seri data, yang memberikan lebih banyak informasi dan memberikan perkiraan yang lebih baik. Penambahan panjang deret waktu adalah efek dari jumlah hari yang berbeda dalam setahun. Secara khusus, kalender Gregorian memiliki 365 hari, sedangkan kalender Lunar memiliki 355 hari. Secara umum, semakin panjang cakrawala peramalan, semakin besar Mean Absolute Percentage Error (MAPE) untuk kalender Gregorian dan Lunar.

Penggunaan kalender lunar berbasis untuk meramalkan curah hujan adalah karena gravitasi bulan mempengaruhi iklim bumi. Selain itu, bulan memberikan pengaruh yang lebih signifikan di bumi daripada matahari karena jaraknya yang lebih dekat. Posisi bulan tidak hanya mempengaruhi fasenya tetapi juga memiliki dampak gravitasi pada cuaca bumi. Pengaruh gaya gravitasi bulan terhadap curah hujan bumi perlu studi lebih lanjut yang melibatkan kolaborasi dengan para astronom.

Kalender lunar umumnya digunakan di negara-negara dengan populasi Muslim sebagai mayoritas, seperti Indonesia, Arab Saudi, dan negara-negara Timur Tengah. Kalender Islam, yang dikenal sebagai kalender Hijriah, berasal dari kalender lunar. Hari libur keagamaan sering mempengaruhi pergerakan signifikan penduduk yang ingin mengunjungi tempat ibadah atau kampung halaman untuk reuni keluarga, mengunjungi orang tua dan kerabat, dll. Akibatnya, kalender lunar memiliki dampak penting pada transportasi dan ekonomi, terutama di negara-negara dengan komunitas Muslim yang besar.

Algoritma pencarian grid yang diusulkan dalam penelitian ini tetap memakan waktu. Setiap kombinasi parameter membutuhkan waktu sekitar dua jam untuk diselesaikan, yang kurang efisien. Oleh karena itu, disarankan untuk mengeksplorasi algoritma alternatif, seperti algoritma genetika.

DAFTAR PUSTAKA

- Abdulwahab, S., Jabreel, M., & Moreno, A. (2017). Deep Learning Models for Paraphrases Identification. doi:10.13140/RG.2.2.15743.46240
- Almodarresi, S. M. T. dan White, N. M. (2004). Calendar conversion for real-time system, *Advances in Engineering Software* Vol. 35, pp. 511-516.
- Apriliadara, M., Suhartono dan Prastyo, D.D., (2016). VARI-X model for currency inflow and outflow forecasting with Eid Fitr effect in Indonesia. *AIP Conference* 1746, 020041 (2016).
- Althelaya, K. A., El-Alfy, E.-S. M., & Mohammed, S. (2018). Stock Market Forecast Using Multivariate Analysis with Bidirectional and Stacked (LSTM, GRU). *2018 21st Saudi Computer Society National Computer Conference (NCC)* (pp. 1-7). IEEE. doi:10.1109/NCG.2018.8593076
- Benjamin, M.A., Rigby R.A., dan Stasinopoulos, D.M. (2003). Generalized Autoregressive Moving Average Models. *Journal of the American Statistical Association*, 98, 214-224.
- Cho, K., Van Merriënboer, B., Bahdanau, D., & Bengio, Y. (2014). On the Properties of Neural Machine Translation: Encoder-Decoder Approaches. *CoRR*. doi:10.48550/ARXIV.1409.1259
- Choi, G., Lee, K., dan Mihn, B. (2018). Science Direct Models of solar and lunar motions in the Chinese Chongxiu-Daming calendar, *Adv. Sp. Res.*, vol. 62, no. 11, pp. 3237-3248.
- Chu, F.-L. (2011). A piecewise linear approach to modeling and forecasting demand for Macau tourism. *Tourism Management*, 36(2), 1414–1420.
- Darmawan, G (2008). Perbandingan Penaksiran Parameter Pembeda Pada Model ARFIMA melalui Metode Regresi Spektral. *Tesis Jurusan Statistika ITS*, Surabaya.
- Darmawan, G., Hendrawati, T., dan Arisanti, R. (2015). Model Auto Singular Spectrum Untuk Meramalkan. *Prosiding Seminar UNY 2015*, 1, 457–462.

- Darmawan, G. (2016). Identifikasi Pola Data Curah Hujan Pada Proses *Grouping* Dalam Metode *Singular Spectrum Analysis*. Prosiding Seminar Nasional Pendidikan Matematika Universitas Muhammadiyah Surakarta, Solo.
- Darmawan, G., Rosadi, D., dan Ruchjana, B.N. (2018). Simulation Study of Singular Spectrum Analysis from Time Series Data With Outlier, *IOP Conference Series: Materials Science and Engineering* 434(1),012068.
- Darmawan, G., Rosadi, D., dan Ruchjana, B.N. (2019a). Forecasting of Internet Usage By Singular Spectrum Analysis With Trend Extraction Method, *AIP Conference Proceedings* 2192,090002.
- Darmawan, G., Rosadi, D., Ruchjana, B.N, Danardono dan Hermansah (2019b). Comparison of sarima modeling from rainfall data in Aceh base on hijriya calendar, *Proceeding of the 62th ISI World Statistics Congress 2019: Contributed Paper Sesion*, Vol.2, CPS1834.
- Darmawan, G., Rosadi, D., dan Ruchjana, B.N. (2020), Daily Forecast for covid-19 During Ramadhan by Singular Spectrum Analysis in Indonesia, *JARDCS*,12(6), pp.818-825.
- Darmawan, G., Rosadi, D., Ruchjana, B.N., dan Hermansah (2021a). Autocorrelation Analysis of Covid-19 based on Hijri Calendar, *Journal of Physics : Conference Series* 1918(4),042004.
- Darmawan, G., Rosadi, D., dan Ruchjana, B.N. (2021b). Covid-19 daily forecasting during Ramadhan in Countries with high muslim populaton. *Journal of Physics : Conference Series* 1722, 12092.
- Darmawan, G., Rosadi, D., Ruchjana, B.N., Pontoh, R.S., Asrirawan dan Wirawan, S. (2022). Forecasting Covid-19 in Indonesia with Various Time Series Models. *Media Statistika* .
- Darmawan, G., Rosadi, D., dan Ruchjana, B.N. (2022b), Hybrid Model of Singular Spectrum Analysis and ARIMA for Seasonal Time Series, *CAUCHY: Jurnal Matematika Murni dan Aplikasi*, Vol.7 No.2 Edition May 2022.
- Dinata, S.A.W, Azka, M, Faisal, M, Suhartono, Yendra, R dan Danil, M. (2020), Short-Term load forecasting double seasonal ARIMA methods: An

- evaluation based on Mahakam-East Kalimantan data. *AIP Conference Proceedings*, 2268, 020004.
- DiPietro, R., & Hager, G. D. (2020). Chapter 21 - Deep learning: RNNs and LSTM. In S. K. Zhou, D. Rueckert, & G. Fichtinger, *Handbook of Medical Image Computing and Computer Assisted Intervention* (pp. 503-519). Academic Press.
- Giarsyani, N. (2020). RETRACTED: Komparasi Algoritma Machine Learning dan Deep Learning untuk Named Entity Recognition : Studi Kasus Data Kebencanaan. *IJAI (Indonesian Journal of Applied Informatics)*, 4(2), 138-144. doi:<http://dx.doi.org/10.20961/ijai.v4i2.41317>.
- Ghods, A., & Cook, D. J. (2019). A Survey of Techniques All Classifiers Can Learn from Deep Networks: Models, Optimizations, and Regularization. doi:10.48550/ARXIV.1909.04791
- Graves, A., Liwicki, M., Fernández, S., Bertolami, R., Bunke, H., & Schmidhuber, J. (2009). A Novel Connectionist System for Unconstrained Handwriting Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31, 855-868. doi:10.1109/TPAMI.2008.137
- Halari, A., Tantisantiwong, N., Power, D. M., dan Helliari, C. (2015). Islamic calendar anomalies : Evidence from Pakistani firm-level data, *Q. Rev. Econ. Financ.*, vol. 58, pp. 64–73.
- Harris, T. J. dan Yuan, H. (2010). Filtering and frequency interpretations of Singular Spectrum Analysis. *Physica D: Nonlinear Phenomena*, 239(20–22), 1958–1967.
- Hikmawati, F, Suhartono dan Prastyio, D.D. (2019). A Hybrid GSTARX-Jordan RNN Model for Forecasting Space-Time Data with Calendar Variation Effect. *Journal of Physics: Conference Series*, 1752 (2021) 012013.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9, 1735-1780. doi:10.1162/neco.1997.9.8.1735
- Hoffman, K. dan Kunze, R. (1971). *Linear Algebra*, Prentice Hall Inc, Englewood Cliffs, New Jersey, USA.

- <https://www.islamicfinder.org/islamic-calendar/>- Di Akses pada Bulan Desember 2018
- Ihaka, R. (2005), *Time Series Analysis, Lecturer Notes for 475.726*, Statistics Departement, University of Auckland.
- Kohyama, T., dan Wallace, J. M. (2016). Rainfall variations induced by the lunar gravitational atmospheric tide and their implications for the relationship between tropical rainfall and humidity. *Geophysical Research Letters*, 918–923.
- Mateus, B. C., Mendes, M., Farinha, J. T., Assis, R., & Cardoso, A. M. (2021). Comparing LSTM and GRU Models to Predict the Condition of a Pulp Paper Press. *Energies*, 14. doi:10.3390/en14216958
- Mohamed, N, Ahmad, M.H, Suhartono dan Ismail, Z (2011), Improving Short Term Load Forecasting Using Double Seasonal Arima Model. *World Applied Science Journal*, 15 (2), 233-231.
- Pan, F., Li, J., Tan, B., Zeng, C., Jiang, X., Liu, L., & Yang, J. (2018). Stacked-GRU Based Power System Transient Stability Assessment Method. *Algorithms*, 11(8). doi:10.3390/a11080121
- Phi, M. (2018). *Illustrated Guide to LSTM's and GRU's: A step by step explanation*. Retrieved 11 October, 2022, from Towards Data Science: <https://towardsdatascience.com/illustrated-guide-to-lstms-and-gru-s-a-step-by-step-explanation-44e9eb85bf21>
- Rashed, M.G., Moklof, M. G., Hamza, A. E., Rashed, M. G., Moklof, M. G., dan Hamza, A. E. (2019). Investigation the Arithmetical or Tabular Islamic calendar, *NRIAG J. Astron. Geophys.*, vol. 7, no. 1, pp. 20–21.
- Rashed, M.G. dan Moklof, M. G. (2017). Suggestion of a conventional Islamic calendar, *NRIAG J. Astron. Geophys.*, vol. 6, no. 2, pp. 275–277.
- Suhartono dan Hamzah, N.A. (2010). Calendar Variation Model based on Time Series Regression for Sales forecasts: The Ramadhan effects. *Proceedings of the Regional Conference on Statistical Sciences*, June 2010, 30-41.

- Suhartono, Lee, M.H., dan Prastyo, D.D. (2015). Two Levels ARIMAX and regression models for forecasting time series data with calendar variation effects. *AIP Conference Proceedings* 1961,050026 (2015).
- Suhartono, Rahayu, S.P., Prastyo, D.D., Wijayanti, D.G.P., dan Julianto. (2017) Hybrid model for forecasting time series with trend,seasonal and salendar variation patterns. *IOP Conf. Series: Journal of Physics: Conf. Series* 890 (2017) 012160
- Suhartono, Gazali, M.M., dan Prastyo, D.D. (2018). VARX and GSTARX Models for Forecasting Currency Inflow and Outflow with Multiple Calendar Variations Effect. *MATEMATIKA*, 2018, Special Issue, 57–72.
- Schuster, M., & Paliwal, K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11), 2673-2681. doi:10.1109/78.650093
- Wei, W.W.W. (2006), *Time Series Analysis Univariate and Multivariate Methods*, In Addison -Wesley Publishing Company. Addison-Wesley Publishing Company.
- Zhang, T., & Xu, R. (2021). Performance Comparisons of Bi-LSTM and Bi-GRU Networks in Chinese Word Segmentation. *Proceedings of the 2021 5th International Conference on Deep Learning Technologies* (pp. 73–80). Association for Computing Machinery. doi:10.1145/3480001.3480011

LAMPIRAN 1 Submit Review Paper

1863346: Revision reminder

External

Print

Close

304

9

+

donal_Journal



The Scientific World Journal <tswj@hindawi.com>
to me

Wed, Nov 8, 11:01AM

☆

↶

⋮



Dear Dr. Gungum Darmawan ,

In order for your submission "IMPROVING THE FORECASTING ACCURACY BASED ON THE LUNAR CALENDAR IN MODELING RAINFALL LEVELS USING THE BI-LSTM METHOD THROUGH THE GRID SEARCH APPROACH" to The Scientific World Journal to proceed further in the review process, you will need to make major revisions to your manuscript.

Reason & Details:

“

before considering the paper for acceptance, please revise the manuscript according to the reviewer's comments.

”

We allow a deadline of 3 months to submit a revised manuscript after a major revision decision. If you require an extension or have any questions, please contact me, and I will be happy to help. If you have already submitted your revised files or have been in touch with us about an extension, you can ignore this automatic reminder.

When you have finished revising, follow the link below to submit your revision:

Submit your revised files

Kind regards,
Polen Ilagan
The Scientific World Journal

Reviewer 1 Comments to the Author

This paper puts forward the BI-LSTM method. The idea is new. However, this manuscript suffers from a number of weak points, it should be further improved before being considered for publication. Let's elaborate on some of them:

- 1) Please check for linguistic and grammatical errors in the paper. The language needs to be improved.
- 2) Check the format and the space of the article. For example, "such as [24] LSTM for sentiment analysis, [25] for Covid-19 Vaccination Responses, [26]" in lines 74-75. Modify the text font to make it consistent.
- 3) The experimental evaluation should compare with multiple algorithms on dataset information. However, it would be helpful to provide additional information about the datasets used, including their characteristics, size, and any preprocessing steps applied. Furthermore, a discussion of the statistical significance of the obtained results would strengthen the validity of the findings.
- 4) When a word abbreviation is first cited, the author must indicate the full name to avoid ambiguity, such as MAPE in the paper.
- 5) It is suggested to use the reference format recommended by the journal. However, some of the references are missing, incomplete, or outdated. Please review the reference list to ensure accuracy and

claims.

6) I noted the conclusion section's brief paragraph addressing future work. However, this failed to consider open research questions (ORQ) identified in the study and related directions for future research. This is important and must be provided.

7) In all such research, an important consideration lies in the practical managerial significance and practical application of the proposed method. A suitable discussion on this topic is required to and show the potential applications for the model and the ability to generalize to multiple domains.

In short, in its current form, the paper is unsuitable for acceptance.

The paper needs rewriting, by addressing the comments as mentioned earlier.

Response

Table 1. Table Response from Author for the first review

No	Reviewer's comments	Author's responses
1	Please check for linguistic and grammatical errors in the paper. The language needs to be improved.	We have improved language so reader can understand easily.
2	Check the format and the space of the article, for example, "such as [24] LSTM for sentiment analysis, [25] for Covid-19 Vaccination Responses, [26]" in lines 74-75. Modify the text font to make it consistent.	The format, space, and fonts have been corrected.
3	The experimental evaluation should compare with multiple algorithms on dataset Information. However, it would be helpful to provide additional information about the datasets used, including their characteristics, size, and any preprocessing steps applied. Furthermore, a discussion of the statistical significance of the obtained results would strengthen the validity of the findings.	We would not compare the experimental evaluation with other algorithms, but it will be suggested as future research.
4	When a word abbreviation is first cited, the author must indicate the full name to avoid ambiguity, such as MAPE in the paper	The first word cited in the abstract has been given the full text, such as MAPE and Bi-LSTM.
5	It is suggested to use the reference format recommended by the journal. However, some of the references are missing, incomplete, or outdated. Please review the reference list to ensure accuracy and include relevant and up-to-date references supporting the paper's claims.	The reference format has been adjusted with the Hindawi's format. Some missing and incomplete references have been added to the references. We have updated the references.
6	I noted the conclusion section's brief paragraph addressing future work. However, this failed to consider open research questions (ORQ) identified in the study and related directions for future research. This is important and must be provided.	We have added two open research questions in the conclusion. They are further research on extreme rainfall data and the use of an

		alternative calendar (Chinese calendar).
7	In all such research, an important consideration lies in the practical managerial significance and practical application of the proposed method. A suitable discussion on this topic is required to and show the potential applications for the model and the ability to generalize to multiple domains.	Lunar calendars are commonly used in countries with substantial Muslim populations, such as Indonesia, Arabia, and various Middle Eastern nations. The Islamic calendar, known as the Hijri calendar, is derived from the lunar calendar. Religious holidays often entail significant movements of residents, including visits to places of worship, hometown reunions, visits to parents and relatives, and more. As a result, the lunar calendar has a notable impact on transportation and the economy of the population, particularly in countries with large Muslim communities.


Lampiran 2 Usulan HAKI




PENGAJUAN HKI

1. Data Pengusul:

Nama Lengkap	: Dr.Gumgum Darmawan,M.Si
Alamat	: Jln. Neglasari VI No.23
Kecamatan	: Cileunyi
Kab./Kota	: Bandung
Provinsi	: Jawa Barat
Kode Pos	: 40621
Email	: gumgum@unpad.ac.id
Hp. Aktif	: 085975273439

FOTO KTP	
TTD DIATAS MATERAI	

Nama Lengkap	: Budhi Handoko,M.Si, Ph.D
Alamat	: komp. Cibiru Asri Blok F.No14
Kecamatan	: Cileunyi
Kab./Kota	: Bandung
Provinsi	: Jawa Barat
Kode Pos	: 40625
Email	: budhi.handoko@unpad.ac.id
Hp. Aktif	: 0812 2917 1845
FOTO KTP	
TTD DIATAS MATERAI	

Nama Lengkap	: Defi Yusti Faidah,M.Si
Alamat	: Rasamala Asri III No.9, Bumi Panyawangan
Kecamatan	: Cileunyi
Kab./Kota	: Bandung
Provinsi	: Jawa Barat
Kode Pos	: 40623
Email	: defi.yusti@unpad.ac.id
Hp. Aktif	: 085649074957
FOTO KTP	
TTD DIATAS MATERAI	

Lampiran 3. Program Software R

```
#####  
##      GREGORIAN DAILY DATA TO LUNAR MONTHLY DATA CONVERTER      ##  
##                               Programmers:                               ##  
##      Gumgum      Darmawan      Budhi      Handoko      Defi      Yusti      Faidah      ##  
#####  
  
mydata_full <- read.csv("curah_hujan_01Jan2000_31Des2022.csv", header = TRUE)  
  
# Determine the 1st Muharram from the dataset.  
# The 1st Muharram is on 5th April 2000 which is on the 96th row  
br <- 96  
hd <- c("bulan", "curah_hujan")  
ld_patterns <- rep(c(30,29),6)  
  
# Analyse the first part of the data  
mydata_init <- mydata_full[1:br,]  
num_dates_i <- ld_patterns  
rev_data <- rev(mydata_init$curah_hujan)  
  
num_dates <- rep(ld_patterns,1)  
Islamic_id <- 1:length(num_dates)  
Islamic_id_rep_i <- rev(rep(Islamic_id,num_dates))  
id_rev <- Islamic_id_rep_i[1:br]  
data_init <- data.frame(rev_data,id_rev)  
result_init <- aggregate(data_init$rev_data, by = list(data_init$id_rev), FUN =  
sum)  
colnames(result_init) <- hd  
  
dummy_init <- 1:(result_init[1,1]-1)  
month_dummy <- rep(NA, result_init[1,1]-1)  
dummy_data_init <- data.frame(dummy_init,month_dummy)  
colnames(dummy_data_init) <- hd  
final_init <- rbind(dummy_data_init, result_init)  
  
#Analyse the rest of the data  
#the First 1 Muharram => row 96
```

```

mydata <- mydata_full[br:length(mydata_full$curah_hujan),]
date_init <- head(mydata$tanggal, n=1)
date_end <- tail(mydata$tanggal, n=1)
n <- length(mydata$curah_hujan)

get_year <- function(mydate){
  year <- format(as.Date(mydate, format="%d-%m-%Y"), "%Y")
}

greg_years <- as.numeric(get_year(c(date_init, date_end)))
hijri_years <- ceiling((greg_years - 622) * 1.03) # Darani et al. (2012)
n_years <- ceiling(dim(mydata)[1]/354)

# Sum the daily rainfall to obtain the monthly rainfall
num_dates <- rep(ld_patterns, n_years)
Islamic_month <- c("Muharram", "Safar", "Rabiul awal", "Rabiul akhir ", "Jumadil
awal", "Jumadil
akhir", "Rajab", "Sya'ban", "Ramadhan", "Syawal", "Dzulkaidah", "Dzulhijjah")
Islamic_id <- 1:length(num_dates)
Islamic_id_rep <- rep(Islamic_id, num_dates)
Islamic_id_rep_trunc <- Islamic_id_rep[1:n]
mydata <- data.frame(mydata, Islamic_id_rep_trunc)
result <- aggregate(mydata$curah_hujan, by = list(Islamic_id_rep_trunc), FUN = sum)

# Add additional months

colnames(result) <- hd
n_dummy_month <- (n_years - length(result$curah_hujan)/12)*12
dummy_month_id <- length(result$curah_hujan) + n_dummy_month
n_add <- (length(result$curah_hujan)+1) : dummy_month_id
n_add_vals <- rep(NA, length(n_add))
add_row <- cbind(n_add, n_add_vals)
colnames(add_row) <- hd
result_add <- rbind(result, add_row)

# Show the result
result_mat <- matrix(result_add$curah_hujan, ncol = n_years, nrow = 12)
hijrs <- c((hijri_years[1]):(hijri_years[2]+2))
result_mat_final <- cbind(final_init$curah_hujan, result_mat)

```

```
rownames(result_mat_final) <- Islamic_month  
colnames(result_mat_final) <- hijrs  
result_mat_final
```

Lampiran 4. Paper UTAMA

Research Paper

IMPROVING THE FORECASTING ACCURACY BASED ON THE LUNAR CALENDAR IN MODELING RAINFALL LEVELS USING THE BI-LSTM METHOD THROUGH THE GRID SEARCH APPROACH

Gumgum Darmawan*, Budhi Handoko, Defi Y. Faidah, Dian Islamiaty

Department of Statistics, Faculty of Mathematics and Natural Sciences

¹Universitas Padjadjaran, Jl.Bandung-Sumedang km 21 Jatinangor Sumedang Indonesia 45363

***Corresponding author:** gumgum@unpad.ac.id

ABSTRACT. *Rainfall is a significant climatic factor that influences various human activities and impacts daily decision-making. However, high-intensity rainfall can pose a threat and lead to various natural disasters, such as floods and landslides. Therefore, it is essential to conduct rainfall forecasting to provide information about potential future dangers, allowing for anticipation and preventive actions. The primary objective of this study is to compare the accuracy of rainfall forecasting between the Gregorian and lunar calendars using the Bidirectional Long Short-Term Memory (Bi-LSTM) machine learning model with the Grid Search approach. This model was selected because it can capture patterns arising from the simultaneous effects of two asynchronous calendars, the Gregorian and Lunar, which were utilized in this study through parameter optimization. Monthly rainfall data from Bogor City, Indonesia, spanning from 2001 to 2022, was employed for analysis. The results indicate that the Mean Absolute Percentage Error (MAPE) for the lunar calendar is 14.82%, signifying superior forecasting accuracy compared to the Gregorian calendar, which has a MAPE of 35.12%.*

KEYWORDS: *BiLSTM, Grid Search, Lunar Calendar, Gregorian Calendar, Forecasting*

INTRODUCTION

Most rainfall forecasting is based on the Gregorian calendar ([1],[2]), but many rainfall phenomena are closely linked to the lunar calendar [3]. Earth's climate including variations in rainfall and tides are influenced by the phases of the moon, which are the cornerstone of making the lunar calendar ([4]). Conversely, rainfall forecasting has generated significant research attention in recent times owing to its complexity and ongoing applications. Hence, methods employing Machine Learning algorithms in conjunction with time series data are being investigated as viable alternatives to address these limitations ([5], [6]).

In recent years, machine learning algorithms have been widely employed for time series data

predictions, yielding highly accurate results. Machine learning enables the resolution of prediction problems in time series data with a wide range of values. Numerous studies have been conducted on rainfall forecasting using machine learning algorithms, including the Support Vector Machine (SVM) method ([7], [8]), the Deep Neural Network (DNN) method ([9], [10]), and the Long Short Term Memory (LSTM) method ([11], [12][13]).

Bidirectional Long Short Term Memory (BiLSTM) is a machine learning method suitable for time series data prediction. It is an extension of LSTM with a capability of retaining data information from both forward and backward directions. This capability enhances the learning process by offering additional neural networks, leading to more comprehensive results. To obtain the best forecasting model using the BiLSTM method, it is essential to determine the optimal parameters for the learning algorithm. Parameter setting and tuning play a significant role in improving forecasting accuracy. One effective approach to determining the optimal parameter setting and tuning is to utilize the grid search algorithm. The grid search algorithm works by systematically combining various parameters used in the model creation process. This method divides the parameter range into a grid and explores different combinations of parameter settings to identify best parameters for the model. According to [16] and [17], the Grid Search technique improved the model performance.

This study covered three aspects of analysis: 1) Rainfall data conversion from Gregorian-based calendar to Lunar-based calendar, 2) Rainfall data modelling and forecasting based on the Lunar calendar, and 3) Comparison of rainfall forecasting accuracy which based on the Gregorian calendar and the Lunar calendar. The purpose of this study is to forecast the rainfall using the Bidirectional Long Short-Term Memory (Bi-LSTM) model by the Grid Search approach. This research is expected to yield an efficient calendar conversion algorithm and can be used as the basis for further research for making an automatization of calendar conversion. Some previous works on calendar conversion were conducted by [18]–[22], [23].

MATERIALS AND METHODS

2.1. Bidirectional Long Short Term Memory (BiLSTM)

LSTM was specifically designed to address the problem of vanishing gradient. LSTM units consist of forget gates, input gates, and output gates, which are used to control the storage or disposal of information. This method has been used in various cases such as sentiment analysis [24], Covid-19 Vaccination Responses [25], and smartphone data sensor [26]. LSTM usually uses quite complex

Commented [JD1]: Ini approach apa maksudnya ya? Apa approach untuk determine optimal parameters? Atau approach untuk setting and tuning parameter? Kalau seperti ini aja tidak jelas.

One effective approach to determining the optimal parameters is...

One effective approach to setting and tuning parameters is utilizing the grid search algorithm

calculations and high computation in its application. Therefore, this study examines a method with a simpler level of computation but have comparable performance, BiLSTM.

BiLSTM was proposed by Graves and Schmidhuber to solve a flaw in the Recurrent Neural Network (RNN) and the LSTM model. In both models, information can only be propagated forward, meaning that the time state t depends only on the information before time t [27]. On the other hand, BiLSTM involves two LSTM networks: processing the sequence of data input in the forward direction and processing the sequence of data in the reverse direction (backward). This method can store time series information in two directions and can provide additional training processes. Additional training processes and two-way feature extraction make BiLSTM has better performance [28]. In addition, the outputs of the forward and backward LSTM networks are combined on each time sequence.

The BiLSTM model can learn past and future information for each input sequence. In addition, BiLSTM has two layers of data input that are opposite to each other which enable the model does not forget a long sequence of data information during the training process [29]. Therefore, theoretically prediction performance with BiLSTM is better than LSTM [30]. The architecture of BiLSTM [31] is provided in Figure 1.




Figure 1. Architecture of Bidirectional LSTM (BiLSTM)

Figure 1 shows the order of the forward layer is the same as in a regular LSTM network that calculates the sequence of $t - 1$, t , then $t + 1$. However, for the backward layer, the hidden layer and output iterated from $t + 1$, t , to $t - 1$. $(\vec{h}_t)$ and $(\overleftarrow{h}_t)$ are the forward and backward layer respectively. According to [32], the process of forward LSTM and backward LSTM can be written as follows

$$\vec{h}_t = LSTM(x_t, h_{t-1}) \quad (1)$$

$$\overleftarrow{h}_t = LSTM(x_t, h_{t+1}) \quad (2)$$

It is described in Figure 1 that the hidden layers on each forward and backward are connected and form an output value. The calculation of the output value is shown in the following equation [33].

$$y_t = U_y \vec{h}_t + W_y \overleftarrow{h}_t + b_y \quad (3)$$

With y_t as the final output value, U_y and W_y as the weight value for the output gate on $\vec{h}_t$ and $\overleftarrow{h}_t$

respectively.

Several studies using the BiLSTM method are conducted by [34] on the case of wastewater flow rate prediction, [35] about tropical cyclone prediction, [36] on groundwater content prediction, and soil [37] about water content and river water flow prediction.

2.3. The Grid Search Method

The Grid Search is a method used for finding appropriate parameters to improve model performance by trying all combinations of parameters. In its applications, the Grid Search algorithm is usually combined with cross-validation to form a model evaluation index. The index evaluates model performance by considering data sharing.

In this paper, the grid search algorithm is evaluated by a Cross-Validation (CV) test. A common form of cross-validation is k -fold, which is used to estimate prediction errors in evaluating model performance. It divides datasets into k groups of equal size. One of the k -fold groups is used as test data while the rest of the groups are used as training data. The parameter pair obtained from the cross-validation test with the smallest error average is the best parameter. This parameter is used in the formation of the model for later testing and evaluation.

3.1. Calendar Conversion

This study utilise algorithm to convert daily data into monthly data based on the Lunar calendar. The month's names and the number of days are referenced from the islamicfinder.com website. The conversion of daily data from the Gregorian to the Lunar calendar requires data division into three segments, as illustrated in Figure 2. The conversion process using the 'TS' package in R software [38] is done through the following steps:

1. Determine the initial and end dates of the lunar calendar.
2. Partition the time interval into three calendar parts.
3. Convert boundary points from the Gregorian calendar to the Lunar calendar.
4. Make these three segments into vector shapes of the dates of the Gregorian and Lunar calendars as seen in Figure 2 below.




Figure 2. Map of Gregorian to Lunar Data Conversion

5. Include calendar attributes i.e., Lunar number and date, e.g., Attr < - c (no, dates).
6. Create a data frame which consist of the combination of the three vectors.
7. Input the daily rainfall data based on Gregorian calendar in a separate column/vector.
8. Merge the column vector of daily data with lunar number and dates into the data frame in Step 6.
9. Shift the daily data according to calendar converter and change the name of Gregorian months to the corresponding Lunar months.

3.2. Preprocessing Data

Data pre-processing stage is carried out to improve performance in data processing and prevent errors in the data so that the data used for prediction process has a high quality. The first stage in the data pre-processing process is data cleaning in which data are adjusted in the presence of missing value. Handling of missing values in data can be done using the mean imputation method, in which missing values are filled up with the average of all known values in a variable.

The second stage is data sharing or data splitting, meaning data are divided into training and testing data. Training data is used in training models, while testing data is used in evaluation of the selection of model architectures with the best parameters. The total data used in this study was 286 lunar calendar data and 273 Gregorian calendar data. These data were divided into several forecasting lengths: 3, 6, 12, 18, and 24 months.

The third stage is called a scaling or mapping technique which is used to normalise data. The normalisation process involves min-max method. The data normalization process will result in values ranging from 0 to 1. According to [30], the equation used in data normalization is as follows.

$$x_{norm,i} = \frac{x_i - x_{min}}{x_{max} - x_{min}} ; i = 1, 2, 3, \dots, t \quad (6)$$

and the denormalization [39] of the data is

$$x = x'(x_{max} - x_{min}) + x_{min} \quad (7)$$

where x_{norm} is a normalised value, x_{max} is the maximum value of the entire data, and x_{min} is the threshold of the entire data.

3.3. BiLSTM-Grid Search Modeling

In building models using machine learning model such as BiLSTM, it is important to select optimal parameters. Parameter determination or tuning parameters are used to control the model so that it can produce better model performance [40]. This study proposed the use of BiLSTM-Grid Search model (see Figure 3).




Figure 3. Proposed Model BiLSTM-Grid Search

BiLSTM modeling with Grid Search consists of input layer, BiLSTM layer, dropout layer, dense layer, and the addition of grid search algorithm to determine the best parameters in the BiLSTM learning process and output layer. The input layer is the layer that receives input data, while the BiLSTM is a layer in the learning process. Dropout layers are used to prevent overfitting of the model during the learning process. The dense layer is a neural network layer that has functions to convert the output of the previous layer into predicted values. The output layer is a layer that produces outputs or final values in the learning process. The addition of a grid search algorithm is used to determine the best parameters, dividing the range of parameters used into grids and at all points in order to get optimal parameters in the learning process of the BiLSTM model.

Some of the parameters used in this study consist of one hidden layer, hidden neurons, batch, and epoch. In addition, dropout regulation techniques are also used to avoid overfitting in the model. Adam's optimization or optimizer function is added to determine the optimal weight and reduce errors in the model formation process to maximize model accuracy. The parameter values set to build the prediction model is given in Table 1 below.

Table 1. Parameter Description

Parameter	Value
Neuron hidden	5, 10, 15, 20, 25
Batch	4, 16, 32, 64, 128
Epoch	50, 100, 150, 200, 250
Dropout	0,1; 0,2; 0,3
Optimizer	Adam

The determination of neuron numbers in the hidden layer is carried out to obtain optimal number of hidden neurons. Epoch is a condition where all data has gone through the training process on the network that is formed until it returns to the beginning in one round. Each epoch can be partitioned into batches. Batch is a parameter that determines sample size used in the process before updating architectural parameters.

The best parameter value from each combination of parameters can be determined using grid search with the help of cross validation. It allows for an evaluation of each model with various

combinations of predefined parameter limit values. A common form of cross-validation is *k*-fold cross-validation. In this study, the grid search algorithm used 5-fold validation. The evaluation calculation for each combination of parameters uses the Mean Square Error (MSE) value.

RESULTS AND DISCUSSION

4.1. Calendar Conversion Results

The results of rainfall data conversion from the Gregorian to the Lunar-based calendar can be seen in Table 2b. The result of the observations of 22 years revealed that the Gregorian calendar has 273 months as seen in table 2a, while the conversion result in the Lunar calendar has 286 months.

Table 2a. Monthly Rainfall data (mm) based on The Gregorian Calendar

Year	Gregorian Month											
	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
2000	-	-	-	449	339	295	376	248	123	222	36	99
2001	219	337	118	581	699	498	368	282	134	70	52	117
2002	376	439	76	635	659	337	339	31	152	186	81	23
2003	47	217	278	138	582	247	266	165	21	0	205	247
2004	291	264	373	292	513	270	355	241	40	74	155	239
2005	188	468	684	417	163	124	163	140	140	207	203	194
2006	264	283	692	446	161	309	132	41	14	6	21	102
2007	160	554	401	395	386	114	7	134	62	167	236	584
2008	311	315	515	516	406	155	63	3	74	160	224	473
2009	254	605	535	385	222	389	128	87	15	64	358	232
2010	417	523	475	84	291	255	138	306	375	427	286	291
2011	389	265	225	219	175	140	36	8	58	284	394	252
2012	384	348	240	318	144	64	41	12	122	260	366	423
2013	851	338	405	344	494	123	275	131	70.1	198.6	259	501.6
2014	1134	623.8	266.7	403.8	219.9	199.1	344.1	249.8	33.6	94.2	548.3	445.7
2015	284.2	345.4	335.7	196.3	148	14.8	0	0	18.8	50.1	457.7	409
2016	272.5	581.7	553.2	461.2	231.2	201.7	252.6	82.6	365.9	386.7	309.6	142.5
2017	293	688.5	283.7	400.8	225.9	130.8	89.1	49.3	33.7	367.4	420.8	320.7
2018	349.1	679.5	448	298.8	140	160.4	25	20.5	161.7	162.4	390.1	251.7
2019	416.3	467.9	234.8	471	207.4	0	51.4	34.8	13.8	196.2	183.8	328.9
2020	421.3	537.1	511.8	344.2	407.6	96.3	95.1	62	100.4	292.6	165.7	343.9
2021	392	687.1	235.4	382.2	155.3	289.6	74.3	189.7	211.6	327	343.8	446

2022 188.2 250 255.3 479.6 242.3 356.3 143.4 278.6 250.7 505.3 299.2 428.7

Tabel 2b. Conversion of Monthly Rainfall (mm) data based on The Lunar Calendar

Year	Lunar Month*											
	Muh	Saf	Raw	Rak	Jaw	Jak	Raj	Syb	Ram	Syw	Dzq	Dzh
1420	-	-	-	-	-	-	-	-	48	493	263	348
1421	329	190	127	218	33	101	210	336	119	475	790	363
1422	482	253	202	54	68	92	204	498	169	239	741	488
1423	320	259	97	71	179	78	23	70	208	283	119	582
1424	247	197	234	17	4	165	286	246	220	287	360	426
1425	405	189	386	120	67	10	99	200	140	171	499	699
1426	365	167	187	187	140	157	154	243	197	241	270	685
1427	461	146	309	132	41	5	15	6	62	149	332	401
1428	1137	408	262	253	100	94	47	102	64	289	227	649
1429	313	500	406	373	120	63	3	113	149	196	473	250
1430	520	612	371	219	399	145	18	82	65	214	315	245
1431	351	523	456	269	198	321	100	185	395	282	375	378
1432	199	409	264	184	231	157	157	13	3	60	201	456
1433	203	347	353	293	332	123	119	43	12	73	170	236
1434	490	506	714	385	340	270	438	135	314	64	102.6	166.1
1435	270.4	495.2	1128	624.1	266.4	394.9	227.9	200	343.2	171	112.9	47.6
1436	517.2	196.9	449.8	404	328.7	223.3	230.6	14.9	0	0	0	55.5
1437	142.7	479.1	354.3	342.7	638.6	466.2	373.6	183.6	258.8	194.7	90.1	358.3
1438	348.7	346.4	134.1	259.5	682.8	318.2	357.7	262.2	91.8	80	101.7	19.7
1439	262.4	370.6	365.1	266.8	684.4	485.8	380.5	109.4	131	159.7	24.8	89.8
1440	94.6	198	410.8	248.8	400.2	468.3	209.5	461	202.8	77.9	51.4	20.8
1441	27.8	190.5	167.9	252.3	383.4	536.9	441.6	449.9	264	288.5	135.7	72.5
1442	35.2	139.5	294.9	303.4	253.5	656.7	381.3	253.2	323.1	158	263.1	154.6
1443	108.8	256.7	312.6	323.9	419.2	124.9	313.3	255.3	471.6	210.6	363.9	175.5
1444	237.6	244.1	444.7	334.1	303.4	198.6	-	-	-	-	-	-

*) The names of lunar month are Muh (Muharram), Saf (Safar), Raw (Rabi’ul Awal), Rak (Rabi’ul Akhir), Jaw (Jumadil Awal), Jak (Jumadil Akhir), Raj (Rajab), Syb (Sya’ban), Dzq (Dzul qo’dah), and Dzh (Dzul hijjah).

4.2. BiLSTM Prediction Results - Grid Search

The data used in BiLSTM modelling were those that passed in data pre-processing stage and parameter tuning was conducted using the grid search algorithm. Based on predetermined parameters, 375 models were obtained from a combination of parameters. Of the 375 models, the most optimal combination of parameters was obtained based on the minimum MSE (Mean Squared Error) value for each forecasting length in the Gregorian lunar calendar which was continued to the testing process. See Table 3 for the complete results.

Table 3. Results of BiLSTM-Grid Search Tuning Parameters on the Gregorian Calendar

Forecasting Length	Parameter				MSE
	Neuron	Batch	Epoch	Dropout	
3	20	4	200	0.1	0.01926
6	20	4	200	0.1	0.01945
12	20	4	200	0.2	0.01882
18	15	4	200	0.1	0.02004
24	20	4	200	0.1	0.01964

Based on the results in Table 3, the smallest MSE was 0.01882 for a 12-month forecasting length with an optimal combination of parameters based on tuning parameters using the grid search are: the number of neurons 20, batch 4, epoch 200, and dropout 0.2. The model with the best combination of parameters obtained from the training data using the grid search was then applied to the testing data. The optimal combination of parameters for rainfall data based on the Lunar calendar is shown in Table 4.

Table 4. BiLSTM-Grid Search Tuning Parameter Results on Lunar Calendar

Forecasting Length	Parameter				MSE
	Neuron	Batch	Epoch	Dropout	
3	20	4	200	0.1	0.01891
6	15	4	200	0.3	0.01907
12	20	4	200	0.3	0.01896
18	20	4	200	0.2	0.01933
24	15	4	200	0.1	0.01926

According to Table 4, the smallest MSE was 0.01891 with a forecasting length of 3 months, number of neurons 20, batch 4, epoch 200, and dropout 0.1. Similar with the one in the Gregorian rainfall data, the model with the best combination of parameters obtained from the training data was then applied to the testing data.

The BiLSTM model was formed using testing data based on the selection of the best parameters. The forecasting length was evaluated using MAPE based on the Lunar and Gregorian lunar calendars which is provided in Table 5 below.

Table 5. MAPE value in the Gregorian and Lunar calendars

Forecasting Length	MAPE	
	Gregorian	Lunar

3	35.12%	14.82%
6	40.27%	15.46%
12	37.29%	26.81%
18	47.36%	40.76%
24	49.14%	42.65%

Table 5 shows the results of model evaluation using MAPE on rainfall data with various forecasting lengths. MAPEs are computed based on the best combination of parameters. The lowest MAPE is the Lunar calendar-based rainfall data with a forecasting length of 3 months. The results in Table 5 conclude that the longer the forecasting, the smaller the MAPE.

The comparison of actual data and forecasting results of rainfall data based on the Gregorian and Lunar calendars using a model with the best parameters for each forecasting length are reported in Figure 3.a and 3.b.




Figure 3. Comparison of Actual Data and Forecasting Results of (a) Gregorian-based Rainfall data (b) Lunar-based Rainfall data

According to Figure 3.a and 3.b, the BiLSTM model that was formed using the best parameter selected using the grid search algorithm on rainfall data based on the Lunar calendar produce predictions that are quite similar to the test data pattern. The MAPE value obtained from rainfall data based on the Lunar calendar was relatively lower than the one from the Gregorian. The lowest MAPE was obtained from the Lunar calendar-based rainfall data at 14.82% with the best parameter values optimized using the Grid Search algorithm: the number of neurons 20, batch 4, epoch 200, and dropout 0.1. The criteria of the MAPE value could confirm the accuracy of the model. In conclusion, the best model obtained from the BiLSTM-Grid Search was able to provide better results in modelling rainfall data based on the Lunar calendar instead of the Gregorian calendar.

DISCUSSION

Converting the Gregorian-based rainfall data to the Lunar calendar gives an advantage in time series analysis. The conversion of daily data to monthly data based on the lunar calendar increases the length of data series, which provides more information and gives a better forecast. The addition in time series length is an effect of different numbers of days in a year. In particular, the Gregorian calendar has 365 days, while the Lunar calendar has 355 days. In general, the longer the forecasting

horizon, the bigger the Mean Absolute Percentage Error (MAPE) for both Gregorian and Lunar calendars.

The use of lunar calendar-based for forecasting rainfall is because the moon's gravity affects the earth's climate. Furthermore, the moon exerts a more significant influence on earth than the sun due to its closer distance. The moon's position not only affects its phases but also has a gravitational impact on earth's weather. The effect of the moon's gravitational force on earth's rainfall needs further study involving collaboration with astronomers.

Lunar calendars are commonly used in countries with Muslim populations as the majority, such as Indonesia, Saudi Arabia, and Middle East countries. The Islamic calendar, known as the Hijri calendar, is derived from the lunar calendar. Religious holidays often affect significant movements of residents who want to visit places of worship or hometown for family reunions, visits parents and relatives, etc. As a result, the lunar calendar has a notable impact on transportation and economy, particularly in countries with large Muslim communities.

The grid search algorithm proposed in this paper remains time-consuming. Each parameter combination takes approximately two hours to complete, which is less efficient. Hence, it is advisable to explore alternative algorithms, such as the genetic algorithm.

CONCLUSIONS

In this paper, we employed the machine learning time series method with the BiLSTM model and the Grid search approach. The accuracy of forecasting results of rainfall data based on the lunar calendar was evaluated using the mean absolute percentage error (MAPE). We also compare the MAPE of the Gregorian calendar-based rainfall data model and the lunar calendar-based rainfall data model.

The lowest MAPE for the Gregorian calendar-based model was 35.12%, while the lowest MAPE for the Lunar calendar-based model was 14.82%, with a forecasting length of 3 months. The smaller MAPE for the Lunar calendar-based model suggests a superior forecasting ability compared to the Gregorian calendar-based model. According to the MAPE criteria, the forecasting model based on the Lunar calendar can be considered highly accurate. The optimal combination of parameters for rainfall data based on the Lunar calendar, as determined through the Grid Search algorithm, comprises 20 neurons, 200 epochs, a batch size of 4, and a dropout value of 0.1.

CONFLICTS OF INTEREST

The authors declare no conflict of interest.

FUNDING STATEMENT

This research was funded by the Acceleration to Senior Lecturer Grant number

ACKNOWLEDGEMENTS

The authors would like to acknowledge Universitas Padjadjaran for funding this research.

REFERENCES

- [1] J. M. J. Abbot, "Skilful rainfall forecasts from artificial neural networks with long duration series and single-month optimization," *J. Abbot, J. Marohasy*, vol. 197, pp. 289–299, Nov. 2017.
- [2] P. Feng *et al.*, "Machine learning-based integration of large-scale climate drivers can improve the forecast of seasonal rainfall probability in Australia," *Environmental Research Letters*, vol. 15, no. 8, Aug. 2020, doi: 10.1088/1748-9326/ab9e98.
- [3] S. Sen Roy, "Impact of lunar cycle on the precipitation in India," *Geophys Res Lett*, vol. 33, no. 1, Jan. 2006, doi: 10.1029/2005GL024771.
- [4] T. Kohyama and J. M. Wallace, "Rainfall variations induced by the lunar gravitational atmospheric tide and their implications for the relationship between tropical rainfall and humidity," *Geophys Res Lett*, vol. 43, no. 2, pp. 918–923, Jan. 2016, doi: 10.1002/2015GL067342.
- [5] Y. Zhang and A. Ye, "Machine Learning for Precipitation Forecasts Postprocessing: Multimodel Comparison and Experimental Investigation", doi: 10.1175/JHM-D-21.
- [6] C. M. Liyew, H. Amsaya, and M. Bahir, "Machine Learning Techniques to Predict Daily Rainfall Amount," *J Big Data*, 2021, doi: 10.21203/rs.3.rs-801241/v1.
- [7] B. T. Pham *et al.*, "Development of advanced artificial intelligence models for daily rainfall prediction," *Atmos Res*, vol. 237, Jun. 2020, doi: 10.1016/j.atmosres.2020.104845.
- [8] Y. Dai and P. Zhao, "A hybrid load forecasting model based on support vector machine with intelligent methods for feature selection and parameter optimization," *Appl Energy*, vol. 279, Dec. 2020, doi: 10.1016/j.apenergy.2020.115332.
- [9] S. Narejo, M. M. Jawaid, S. Talpur, R. Baloch, and E. G. A. Pasero, "Multi-step rainfall forecasting using deep learning approach," *PeerJ Comput Sci*, vol. 7, pp. 1–23, 2021, doi: 10.7717/PEERJ-CS.514.
- [10] C. C. Wei and T. H. Chou, "Typhoon quantitative rainfall prediction from big data analytics by using the apache hadoop spark parallel computing framework," *Atmosphere (Basel)*, vol. 11, no. 8, Aug. 2020, doi: 10.3390/ATMOS11080870.
- [11] X. Chen *et al.*, "The importance of short lag-time in the runoff forecasting model based on long short-term memory," *J Hydrol (Amst)*, vol. 589, Oct. 2020, doi: 10.1016/j.jhydrol.2020.125359.
- [12] D. H. Nguyen, J. B. Kim, and D. H. Bae, "Improving radar-based rainfall forecasts by long short-term memory network in urban basins," *Water (Switzerland)*, vol. 13, no. 6, Mar. 2021, doi: 10.3390/w13060776.
- [13] D. Endalgie, G. Haile, and W. Taye, "Deep learning model for daily rainfall prediction: case study of Jimma, Ethiopia," *Water Supply*, vol. 22, no. 3, pp. 3448–3461, Mar. 2022, doi: 10.2166/WS.2021.391.
- [14] X. mei Yu, W. zhi Feng, H. Wang, Q. Chu, and Q. Chen, "An attention mechanism and multi-granularity-based Bi-LSTM model for Chinese Q&A system," *Soft comput*, vol. 24, no. 8, pp. 5831–5845, Apr. 2020, doi: 10.1007/s00500-019-04367-8.
- [15] J. Luo and X. Zhang, "Convolutional neural network based on attention mechanism and Bi-LSTM for bearing remaining life prediction," *Applied Intelligence*, vol. 52, pp. 1076–1091, 2022, doi: 10.1007/s10489-021-02503-2/Published.
- [16] S. Jarak, S. Ahmed, and M. S. Alouini, "Low Complexity Moving Target Parameter Estimation for MIMO Radar Using 2D-FFT," *IEEE Transactions on Signal Processing*, vol. 65, no. 18, pp. 4745–4755, Sep. 2017, doi: 10.1109/TSP.2017.2716910.
- [17] C. Dagli and T. S. Huang, "A Framework for Grid-Based Image Retrieval."
- [18] A. Halari, N. Tantisantiwong, D. M. Power, and C. Helliart, "Islamic calendar anomalies: Evidence from Pakistani firm-level data," *Quarterly Review of Economics and Finance*, vol. 58, pp. 64–73, Nov. 2015, doi: 10.1016/j.qref.2015.02.004.
- [19] M. G. Rashed, M. G. Moklof, and A. E. Hamza, "Investigation the Arithmetical or Tabular Islamic calendar," *NRIAG Journal of Astronomy and Geophysics*, vol. 7, no. 1, pp. 20–21, Jun. 2018, doi: 10.1016/j.nrjag.2017.12.005.
- [20] G. E. Choi, K. W. Lee, and B. H. Mihn, "Models of solar and lunar motions in the Chinese Chongxiu-Daming calendar," *Advances in Space Research*, vol. 62, no. 11, pp. 3237–3248, Dec. 2018, doi: 10.1016/j.asr.2018.08.024.
- [21] S. M. T. AlModarresi and N. M. White, "Calendar conversion for real-time systems," *Advances in*

- Engineering Software*, vol. 35, no. 8–9, pp. 511–516, 2004, doi: 10.1016/j.advengsoft.2004.05.004.
- [22] M. G. Rashed and M. G. Moklof, “Suggestion of a conventional Islamic calendar,” *NRIAG Journal of Astronomy and Geophysics*, vol. 6, no. 2, pp. 275–277, Dec. 2017, doi: 10.1016/j.nrjag.2017.06.004.
- [23] G. Darmawan, D. Rosadi, and B. N. Ruchjana, “Daily forecast for covid-19 during ramadhan by singular spectrum analysis in Indonesia,” *Journal of Advanced Research in Dynamical and Control Systems*, vol. 12, no. 6, 2020, doi: 10.5373/JARDCS/V12I6/S20201097.
- [24] A. Ligthart, C. Catal, and B. Tekinerdogan, “Systematic reviews in sentiment analysis: a tertiary study,” *Artif Intell Rev*, vol. 54, no. 7, pp. 4997–5053, Oct. 2021, doi: 10.1007/s10462-021-09973-3.
- [25] F. Rustam, M. Khalid, W. Aslam, V. Rupapara, A. Mehmood, and G. S. Choi, “A performance comparison of supervised machine learning models for Covid-19 tweets sentiment analysis,” *PLoS One*, vol. 16, no. 2, Feb. 2021, doi: 10.1371/journal.pone.0245909.
- [26] S. Mekruksavanich and A. Jitpattanakul, “Lstm networks using smartphone data for sensor-based human activity recognition in smart homes,” *Sensors*, vol. 21, no. 5, pp. 1–25, Mar. 2021, doi: 10.3390/s21051636.
- [27] G. Xu, Y. Meng, X. Qiu, Z. Yu, and X. Wu, “Sentiment analysis of comment texts based on BiLSTM,” *IEEE Access*, vol. 7, pp. 51522–51532, 2019, doi: 10.1109/ACCESS.2019.2909919.
- [28] S. Liang, D. Wang, J. Wu, R. Wang, and R. Wang, “Method of bidirectional lstm modelling for the atmospheric temperature,” *Intelligent Automation and Soft Computing*, vol. 30, no. 2, pp. 701–714, 2021, doi: 10.32604/iasc.2021.020010.
- [29] C. Cai, Y. Tao, T. Zhu, and Z. Deng, “Short-term load forecasting based on deep learning bidirectional lstm neural network,” *Applied Sciences (Switzerland)*, vol. 11, no. 17, Sep. 2021, doi: 10.3390/app11178129.
- [30] M. Yang and J. Wang, “Adaptability of Financial Time Series Prediction Based on BiLSTM,” in *Procedia Computer Science*, Elsevier B.V., 2021, pp. 18–25. doi: 10.1016/j.procs.2022.01.003.
- [31] Z. Cui, R. Ke, Z. Pu, and Y. Wang, “Stacked Bidirectional and Unidirectional LSTM Recurrent Neural Network for Forecasting Network-wide Traffic State with Missing Values,” May 2020, [Online]. Available: <http://arxiv.org/abs/2005.11627>
- [32] Z. Hameed and B. Garcia-Zapirain, “Sentiment Classification Using a Single-Layered BiLSTM Model,” *IEEE Access*, vol. 8, pp. 73992–74001, 2020, doi: 10.1109/ACCESS.2020.2988550.
- [33] J. Kim and N. Moon, “BiLSTM model based on multivariate time series data in multiple field for forecasting trading area,” *J Ambient Intell Humaniz Comput*, 2019, doi: 10.1007/s12652-019-01398-9.
- [34] H. Kang, S. Yang, J. Huang, and J. Oh, “Time Series Prediction of Wastewater Flow Rate by Bidirectional LSTM Deep Learning,” *Int J Control Autom Syst*, vol. 18, no. 12, pp. 3023–3030, Dec. 2020, doi: 10.1007/s12555-019-0984-6.
- [35] P. Varalakshmi, N. Vasumathi, and R. Venkatesan, “Tropical Cyclone prediction based on multi-model fusion across Indian coastal region,” *Prog Oceanogr*, vol. 193, Apr. 2021, doi: 10.1016/j.pocean.2021.102557.
- [36] F. Granata, F. Di Nunno, M. Najafzadeh, and I. Demir, “A Stacked Machine Learning Algorithm for Multi-Step Ahead Prediction of Soil Moisture,” *Hydrology*, vol. 10, no. 1, Jan. 2023, doi: 10.3390/hydrology10010001.
- [37] R. K. Vogeti, B. R. Mishra, and K. S. Raju, “Machine learning algorithms for streamflow forecasting of Lower Godavari Basin,” *H2Open Journal*, vol. 5, no. 4, pp. 670–685, Dec. 2022, doi: 10.2166/h2oj.2022.240.
- [38] G. Darmawan, D. Rosadi, B. N. Ruchjana, and Hermansah, “Autocorrelation analysis of COVID-19 based on hijri calendar,” in *Journal of Physics: Conference Series*, 2021. doi: 10.1088/1742-6596/1918/4/042004.
- [39] H. Zeng, B. Shao, G. Bian, H. Dai, and F. Zhou, “A hybrid deep learning approach by integrating extreme gradient boosting-long short-term memory with generalized autoregressive conditional heteroscedasticity family models for natural gas load volatility prediction,” *Energy Sci Eng*, vol. 10, no. 7, pp. 1998–2021, Jul. 2022, doi: 10.1002/ese3.1122.
- [40] I. Priyadarshini and C. Cotton, “A novel LSTM–CNN–grid search-based deep neural network for sentiment analysis,” *Journal of Supercomputing*, vol. 77, no. 12, pp. 13911–13932, Dec. 2021, doi: 10.1007/s11227-021-03838-w.